

README - Générateur de données et import Snowflake

1. DESCRIPTION

Ce script Python génère des jeux de données factices (clients, inventaire, commandes) puis les importe automatiquement dans Snowflake.

Il est conçu pour :

- Créer des DataFrames simulant un environnement e-commerce
- Normaliser les colonnes (MAJUSCULES) pour compatibilité Snowflake
- Créer les tables nécessaires dans Snowflake
- Charger les DataFrames via la méthode optimisée write_pandas

Tables générées :

- CUSTOMERS
- INVENTORY
- ORDERS

2. PRÉREQUIS

- Python 3.9+
- Packages Python:

pandas

faker

snowflake-connector-python

snowflake-connector-python[pandas]

Installer les dépendances :

pip install pandas faker snowflake-connector-python

"snowflake-connector-python[pandas]"

3. CONFIGURATION

Paramètres Snowflake à modifier dans le code principal :

```
user='Pollom'
password='***'
account='tjkpvvb-gw55905'
warehouse='mon_entrepot'
database='ma_base'
schema='mon_schema'
```

Recommandation sécurité :

- Utiliser des variables d'environnement pour le mot de passe au lieu de l'écrire en dur.

4. UTILISATION

Exécuter simplement le script :

python generate_and_load.py

Étapes réalisées automatiquement :

- 1. Génération des DataFrames (CUSTOMERS, INVENTORY, ORDERS)
- 2. Connexion à Snowflake
- 3. Création des tables (ou remplacement si elles existent déjà)
- 4. Chargement des données dans Snowflake
- 5. Vérification avec SELECT COUNT(*)

5. VÉRIFICATION

Depuis Snowsight ou SnowSQL, exécuter :

USE WAREHOUSE mon_entrepot;

USE DATABASE ma base;

USE SCHEMA mon_schema;

SELECT COUNT(*) FROM CUSTOMERS;

SELECT COUNT(*) FROM INVENTORY;

SELECT COUNT(*) FROM ORDERS;

SELECT * FROM CUSTOMERS LIMIT 10;

SELECT * FROM INVENTORY LIMIT 10;

SELECT * FROM ORDERS ORDER BY SOLD AT DESC LIMIT 10;

6. NOTES DE SÉCURITÉ

- Ne pas laisser les identifiants en clair dans le code (utiliser variables d'environnement).
- Vérifier que votre rôle Snowflake a les droits sur le warehouse/base/schema.
- Les tables sont recréées à chaque exécution (CREATE OR REPLACE TABLE).

7. EXTENSIONS POSSIBLES

- Passer en mode "append" (overwrite=False dans write_pandas).
- Ajouter un volume de données plus important.
- Utiliser TIMESTAMP_TZ si la conservation du fuseau horaire est nécessaire.
- Déployer dans un job automatisé (Airflow, Prefect, cron).

Script : generate_and_load.py

Auteur: Paul Description:

> Génère des données factices (clients, inventaire, commandes) et les importe dans Snowflake.

Fonctionnalités principales :

- Génération de DataFrames via Faker et distributions aléatoires
- Normalisation des colonnes en MAJUSCULE pour compatibilité Snowflake
- Création des tables Snowflake avec un schéma explicite
- Chargement des données via write_pandas

import datetime import random import pandas as pd from faker import Faker

--- Snowflake --import snowflake.connector from snowflake.connector.pandas_tools import write_pandas

def gaussian_clamped(rng: random.Random, mu: float, sigma: float, a: float, b: float) -> float:

Tire une valeur aléatoire suivant une loi normale tronquée entre a et b.

Args:

rng (random.Random): générateur aléatoire mu (float): moyenne sigma (float): écart-type a (float): minimum b (float): maximum

Returns:

float: valeur comprise entre a et b val = rng.gauss(mu, sigma) return max(a, min(b, val))

def generate_orders(orders: int,

seed: int = 42,

```
start: str = "2024-01-01",
  end: str = "2025-09-01",
  inventory: pd.DataFrame = None,
  customers: pd.DataFrame = None,
) -> pd.DataFrame:
  Génère un DataFrame de commandes factices.
  Args:
     orders (int): nombre de commandes
    seed (int): graine aléatoire
    start (str): date de début (YYYY-MM-DD)
    end (str): date de fin (YYYY-MM-DD)
    inventory (pd.DataFrame): produits disponibles
    customers (pd.DataFrame): clients disponibles
  Returns:
    pd.DataFrame: tableau des commandes
  rng = random.Random(seed)
  # Plage temporelle pour SOLD_AT
  start_dt = datetime.datetime.fromisoformat(start).replace(tzinfo=datetime.timezone.utc)
  end_dt = datetime.datetime.fromisoformat(end).replace(tzinfo=datetime.timezone.utc)
  delta_seconds = int((end_dt - start_dt).total_seconds())
  # Produits et prix
  product ids = list(range(1000, 1250))
  prices = {}
  if inventory is not None and not inventory.empty:
    product_ids = inventory["PRODUCT_ID"].tolist()
    prices = dict(zip(inventory["PRODUCT_ID"], inventory["UNIT_PRICE"], strict=True))
  # Clients
  customer_ids = list(range(1, 1001))
  if customers is not None and not customers.empty:
    customer_ids = customers["CUSTOMER_ID"].tolist()
  rows = []
  for i in range(1, orders + 1):
    pid = rng.choice(product_ids)
    qty = rng.choices([1, 2, 3, 4, 5], weights=[0.6, 0.2, 0.12, 0.06, 0.02])[0]
    sold at = start dt + datetime.timedelta(seconds=rng.randint(0, delta seconds))
    cid = rng.choice(customer_ids)
    unit price = prices.get(pid, round(rng.uniform(5, 500), 2))
    rows.append(
       {
          "ID": i,
```

```
"PRODUCT_ID": pid,
          "CUSTOMER_ID": cid,
          "QUANTITY": qty,
         "UNIT_PRICE": unit_price,
         "SOLD AT": sold at,
       }
    )
  df = pd.DataFrame(rows)
  df["SOLD AT"] = pd.to datetime(df["SOLD AT"], utc=True)
  return df
# Catégories et adjectifs pour générer l'inventaire
CATEGORIES = [
  ("Apparel", ["T-Shirt", "Hoodie", "Jeans", "Sneakers", "Jacket"]),
  ("Electronics", ["Headphones", "Smartphone", "Tablet", "Smartwatch", "Charger"]),
  ("Home & Kitchen", ["Mug", "Kettle", "Blender", "Vacuum", "Toaster"]),
  ("Beauty", ["Shampoo", "Conditioner", "Face Cream", "Perfume", "Lipstick"]),
  ("Grocery", ["Coffee Beans", "Olive Oil", "Pasta", "Granola", "Tea"]),
]
ADJECTIVES = ["Classic", "Premium", "Eco", "Urban", "Sport", "Comfort", "Pro", "Lite",
"Max", "Essential"]
def generate_inventory_data(products: int, seed: int = 42) -> pd.DataFrame:
  Génère un DataFrame d'inventaire de produits factices.
  Args:
    products (int): nombre de produits
    seed (int): graine aléatoire
  Returns:
    pd.DataFrame: tableau des produits
  rng = random.Random(seed)
  rows = []
  product ids = list(range(1000, 1000 + products))
  for pid in product ids:
    cat, names = rng.choice(CATEGORIES)
    base = rng.choice(names)
    adj = rng.choice(ADJECTIVES)
    product_name = f"{adj} {base}"
    base price = {"Apparel": 39, "Electronics": 299, "Home & Kitchen": 79, "Beauty": 25,
"Grocery": 12}[cat]
    price = round(gaussian_clamped(rng, base_price, base_price * 0.25, base_price * 0.4,
base price * 1.8), 2)
```

```
stock_qty = int(gaussian_clamped(rng, 80, 60, 0, 400))
    rows.append(
       {
         "PRODUCT_ID": pid,
         "PRODUCT NAME": product name,
         "CATEGORY": cat,
         "UNIT_PRICE": price,
         "STOCK_QUANTITY": stock_qty,
    )
  return pd.DataFrame(rows)
def generate_customers(customers: int, seed: int = 42) -> pd.DataFrame:
  Génère un DataFrame de clients factices.
  Args:
    customers (int): nombre de clients
    seed (int): graine aléatoire
  Returns:
    pd.DataFrame: tableau des clients
  rng = random.Random(seed)
  fake = Faker()
  Faker.seed(seed)
  rows = []
  channels = [("online", 0.65), ("store", 0.35)]
  for cid in range(1, customers + 1):
    name = fake.name()
    email = fake.email()
    city = fake.city()
    channel = rng.choices([c for c, _ in channels], weights=[w for _, w in channels])[0]
    rows.append(
       {
         "CUSTOMER ID": cid,
         "NAME": name,
         "EMAIL": email,
         "CITY": city,
         "CHANNEL": channel,
       }
    )
  return pd.DataFrame(rows)
def create tables if needed(conn):
```

,,,,,,

Crée (ou remplace) les tables CUSTOMERS, INVENTORY, ORDERS dans Snowflake.

```
Args:
    conn: connexion active Snowflake
  ddI = [
    CREATE OR REPLACE TABLE CUSTOMERS (
      CUSTOMER_ID INTEGER,
      NAME STRING,
      EMAIL STRING,
      CITY STRING,
      CHANNEL STRING
    );
    ,,,,,,,
    ******
    CREATE OR REPLACE TABLE INVENTORY (
      PRODUCT_ID INTEGER,
      PRODUCT_NAME STRING,
      CATEGORY STRING,
      UNIT_PRICE NUMBER(10,2),
      STOCK_QUANTITY INTEGER
    );
    ******
    ******
    CREATE OR REPLACE TABLE ORDERS (
      ID INTEGER,
      PRODUCT_ID INTEGER,
      CUSTOMER ID INTEGER,
      QUANTITY INTEGER,
      UNIT_PRICE NUMBER(10,2),
      SOLD_AT TIMESTAMP_NTZ
    );
    ,,,,,,,
  with conn.cursor() as cur:
    for stmt in ddl:
      cur.execute(stmt)
def load_df(conn, df: pd.DataFrame, table: str):
  Charge un DataFrame dans une table Snowflake.
  Args:
    conn: connexion active Snowflake
    df (pd.DataFrame): DataFrame à charger
```

```
table (str): nom de la table cible
  if table.upper() == "ORDERS" and "SOLD AT" in df.columns:
    df = df.copy()
    df["SOLD AT"] = pd.to datetime(df["SOLD AT"], utc=True).dt.strftime('%Y-%m-%d
%H:%M:%S')
  success, nchunks, nrows, _ = write_pandas(
    conn,
    df,
    table_name=table,
    overwrite=True,
    auto_create_table=False,
    quote_identifiers=True,
  )
  print(f" Table {table}: {nrows} lignes chargées ({'OK' if success else 'KO'})")
def show_counts(conn):
  Affiche le nombre de lignes dans chaque table cible.
  Args:
    conn: connexion active Snowflake
  with conn.cursor() as cur:
    for t in ["CUSTOMERS", "INVENTORY", "ORDERS"]:
       cur.execute(f"SELECT COUNT(*) FROM {t}")
       print(f'') = \{cur.fetchone()[0]\} \ lignes''
if __name__ == "__main__":
  #1) Génération des données locales
  customers_df = generate_customers(customers=100, seed=42)
  inventory_df = generate_inventory_data(products=100, seed=42)
  orders_df = generate_orders(orders=100, seed=42, inventory=inventory_df,
customers=customers_df)
  #2) Connexion Snowflake
  conn = snowflake.connector.connect(
    user='Pollom',
    password='dCZFA4nmEbRqiqz',
    account='tjkpvvb-gw55905',
    warehouse='mon_entrepot',
    database='ma base',
    schema='mon_schema'
  )
```

```
try:
# 3) Création / remplacement des tables
create_tables_if_needed(conn)

# 4) Chargement des DataFrames
load_df(conn, customers_df, "CUSTOMERS")
load_df(conn, inventory_df, "INVENTORY")
load_df(conn, orders_df, "ORDERS")

# 5) Vérification rapide
show_counts(conn)

# Info version Snowflake
with conn.cursor() as cur:
    cur.execute("SELECT current_version()")
    print(f" Snowflake version: {cur.fetchone()[0]}")

finally:
    conn.close()
```